

## 宋林蔚

大模型应用 / AI Agent 工程师

电话 18059396679  
GitHub [github.com/fjnuslw](https://github.com/fjnuslw)  
出生 2001.09

邮箱 1147214246@qq.com  
主页 [fjnuslw.github.io](https://fjnuslw.github.io)  
现居 福建 · 福州



## 实习经验

2026.07—2026.09

友达光电 卓越工程师计划

AI 专案实习生

- 新 model 上线需按站点写 SOP/OI，依赖 key-in 与拍照贴图，规范不一致、审核慢，拖住 China Car 放量。
- 负责 FIDM 新产品 SOP 智撰 Agent：工序/关键画面理解 → 结构化草案 → 人工审校闭环，工作从「从零录入」改为「审校优化」。
- 目标：编写耗时约 -50%，OI 自动生成准确率 ≥90%，支持 Lessons Learned 一键回写。

2025.07—2026.02

福建新意科技有限公司

大模型应用开发

- 企业智能客服 RAG：业务知识梳理、Dify Workflow 编排、多模型接入，持续迭代 Prompt 与命中效果。
- 长文档层级深、版本更新快。设计树状切分 + 全文索引，以召回/命中/答案完整性对比普通分段与父子索引后定版。
- 部署 Qwen-32B (vLLM) 与 CPU 侧 Embedding/Rerank (Xinference)；接入 MCP 与多供应商 API 并排障。
- 自建 20 题业务评测集（准确性、证据相关性、完整性、稳定性），用失败 case 驱动知识库与选型。

## 项目经验

2026.07—至今

Local Window Copilot

独立开发 · 开源

- 独立实现 local-first Windows 桌面 Copilot：Win32 透明置顶悬浮窗（自动排除截屏）观察前台应用，MiniCPM-V 产出结构化证据，llama.cpp + FastAPI/SSE 完成本地流式对话。
- 将观察与对话解耦：后台只沉淀带 record\_id / 截图的证据，不默认注入 prompt；模型仅通过 memory.search 按需检索，避免陈旧观察污染并让回答可追溯。
- 针对 MiniCPM-V function calling 不稳，设计 probe→stream(+tool loop)：probe 只认结构化 tool\_calls，stream 保留二次取证机会；以 FT55/BM25 + 中文 bigram 替换 VLM reranker，将证据排序从 12-30s 降至毫秒级。
- 构建本地长上下文治理：冻结 system/profile 前缀复用 llama.cpp KV cache，加入分段 token 账本、请求前拦截、工具结果预算与 rolling compact；WebUI 可回放证据/调用/压缩/日志，263/263 项测试通过。

项目链接：<https://github.com/fjnuslw/local-window-copilot>

## 竞赛获奖

全国总决赛 · 一等奖 · 全国第 5 名  
第十七届蓝桥杯全国大学生软件和信息技术大赛  
人工智能赛 · 智能体开发大学组  
↗ 国赛获奖名单 ↗ 证书核验

福建赛区省赛 · 一等奖 · 福建省第 1 名 · 晋级国赛  
第十七届蓝桥杯全国大学生软件和信息技术大赛  
人工智能赛 · 智能体开发大学组  
↗ 省赛获奖名单 ↗ 证书核验

## 教育背景

2025.09—至今

福建师范大学  
2025 年研究生一等奖学业奖学金

软件工程（硕士）

2020.09—2024.06

福州大学至诚学院  
英语六级（CET-6）

计算机科学与技术（本科）

## 论文

2026 · CCF-B

Intrinsic Attention as Navigator: A Non-Generative Retrieval Method for Multi-Hop Queries

一作 · EMNLP 2026

- 发现 Embedding 模型 elite attention heads 可稳定定位跨文档桥接线索，实现无需 CoT、训练或预构图的 next-hop 检索。
- 指令激活桥接 clue；semantic residual 逐跳扣除已覆盖语义，beam 保留多路径，避免检索停留在原问题语义邻域。
- Qwen3-Embedding-4B 在 2Wiki / MuSiQue 的 R@5 达 89.10 / 76.45，相对 Direct +16.28 / +12.65，并超过 8B 直检；移除 intrinsic steering 后分别下降 18.0 / 9.7 点。ARR 3.5 3.0 2.5

2026 · JCR Q1

ESRA: Training-Free Multi-Hop Agentic RAG with Explicit Evidence-State Transitions

AI Open

- 将多跳 Agent 的瓶颈定位为证据状态失控：自然语言轨迹无法约束当前关系、分支和答案槽，易状态漂移与跨分支串证据。
- PlanState 定位 branch/step，Search/Probe 构造带来源候选，Workspace 保存完整输出、只显当前分支；经校验的 candidate commit 写回，并区分候选构建/提交错误。
- 同骨干/索引下三数据集均优于 Direct、Standard RAG、IR-CoT、MA-RAG；bridge-comparison F1 0.889 vs 0.674，工具 observation -90.4%；移除 Workspace 后 Avg F1 0.673→0.208、loops 5.10→10.52。

## 技能特长

RAG 工程

AI Agent

Tool Calling

Agent Workflow

LangGraph / LangChain

Dify

FastAPI

Python

本地模型部署

评测与迭代