

宋林蔚

大模型应用 / AI Agent 工程师

电话 18059396679
GitHub github.com/fjnuslw
出生 2001.09

邮箱 1147214246@qq.com
主页 fjnuslw.github.io
现居 福建 · 福州



实习经验

2026.07—2026.09

友达光电

卓越工程师计划

AI 专案实习生

- 新 model 上线需按站点写 SOP/OI，依赖 key-in 与拍照贴图，规范不一致、审核慢，拖住 China Car 放量。
- 负责 FIDM 新产品 SOP 智撰 Agent：工序/关键画面理解 → 结构化草案 → 人工审校闭环，工作从「从零录入」改为「审校优化」。
- 目标：编写耗时约 -50%，OI 自动生成准确率 ≥90%，支持 Lessons Learned 一键回写。

2025.07—2026.02

福建新意科技有限公司

大模型应用开发

- 企业智能客服 RAG：业务知识梳理、Dify Workflow 编排、多模型接入，持续迭代 Prompt 与命中效果。
- 长文档层级深、版本更新快。设计树状切分 + 全文索引，以召回/命中/答案完整性对比普通分段与父子索引后定版。
- 部署 Qwen-32B (vLLM) 与 CPU 侧 Embedding/Rerank (Xinference)；接入 MCP 与多供应商 API 并排障。
- 自建 20 题业务评测集（准确性、证据相关性、完整性、稳定性），用失败 case 驱动知识库与选型。

项目经验

2026.07—至今

Local Window Copilot

独立开发 · 开源

- Windows 本地桌面 Agent (local-first)。观察线：截图 → MiniCPM-V 结构化卡片 → SQLite；对话线：ChatAgent 仅暴露 memory.search，FastAPI/SSE 流式输出并绑定证据 id。
- 小 VLM tool-call 不稳：拆 probe → stream (probe 判是否调工具，stream 出终答)，确定性 FTS 替换 VLM ranker → 失败率 46% → 0%，排名延迟 ~30s → 10ms。
- 上下文分层 system / profile / session / evidence；冻结 profile 稳 prefix cache，首 Token -30%~60%；收紧观察契约后 VLM 成功率 54% → 80%。
- 请求前 token 预算拦截 + rolling compact；WebUI 回放观察 JSON / 截图 / tool trace；55 项单测覆盖主路径。

项目链接：<https://github.com/fjnuslw/local-window-copilot>

竞赛获奖

全国总决赛 · 一等奖 · 全国第 5 名

第十七届蓝桥杯全国大学生软件和信息技术大赛
人工智能赛 · 智能体开发大学组[国赛获奖名单](#) [证书核验](#)

福建赛区省赛 · 一等奖 · 福建省第 1 名 · 晋级国赛

第十七届蓝桥杯全国大学生软件和信息技术大赛
人工智能赛 · 智能体开发大学组[省赛获奖名单](#) [证书核验](#)

教育背景

2025.09—至今

福建师范大学

2025 年研究生一等奖学业奖学金

软件工程（硕士）

2020.09—2024.06

福州大学至诚学院

英语六级（CET-6）

计算机科学与技术（本科）

论文

2026 · CCF-B

Intrinsic Attention as Navigator: A Non-Generative Retrieval Method for Multi-Hop Queries

一作 · EMNLP 2026

- 多跳 RAG 证据链断裂：单次稠密检索易停在问题语义邻域，显式生成中间推理又易误差放大。提出 training-free 非生成式检索，读 Embedding elite attention heads 抽 next-hop 桥接线索。
- 指令激活注意力头 → 线索召回 → 语义残差重排（剥离已表达线索，residual 找未覆盖证据）→ beam 多路径；骨干 Qwen3-Embedding-4B。
- HotpotQA / 2Wiki / MuSiQue 全面优于 BM25、GTR 与同规模 Direct；相对 4B Direct，MuSiQue / 2Wiki 主召回约 +12.7 / +16.3，常打平甚至反超 8B 直检。ARR 3.5 3.0 2.5

2026 · JCR Q1

ESRA: Training-Free Multi-Hop Agentic RAG with Explicit Evidence-State Transitions

一作 · AI Open

- 多跳 agentic RAG 难在中间判断写回：轨迹 / observation 管不住当前关系、分支归属、已接受证据与答案槽位，易漂移与跨分支混用。
- PlanState 管路线/分支/答案目标；Search/Probe 将检索压成句/实体/答案候选；Workspace 存完整工具输出、模型只读分支 slim 视图；LLM 以 candidate commit 写回可执行状态。
- 2Wiki / HotpotQA / MuSiQue (各 500) 超 Direct、Standard RAG、IR-CoT、MA-RAG；2Wiki EM/F1 0.442/0.550 → 0.674/0.764；bridge-comparison F1 0.889 vs 0.674；observation 约 -90%；去 Workspace 后 F1 0.673 → 0.208。

技能特长

RAG 工程

AI Agent

Tool Calling

Agent Workflow

LangGraph / LangChain

Dify

FastAPI

Python

本地模型部署

评测与迭代